

Rapport du projet de session

PhyloDendron - Création d'un site web d'inférence d'arbres phylogénétiques

Session Hiver 2026

Date de remise : 06 mai 2026 à 23h59

Enseignant : Dylan Lebatteux

Chelsea Baek et Mariyana Slavova

Table des matières

1 Résumé	2
2 Introduction et problématique	2
2.1 Le contexte scientifique et la motivation du projet	2
2.2 La problématique ou la question de recherche	2
2.3 Les objectifs	2
3 Méthodes et matériel	2
3.1 Les données utilisées	2
3.2 Les algorithmes, outils et logiciels	2
3.3 Le protocole	5
4 Résultats et discussion	5
4.1 Les résultats	5
4.2 Analyse et interprétation des résultats	5
4.3 Les forces et les limites	5
4.4 Comparaison	5
5 Conclusion	5
6 Références	5

1 Résumé

2 Introduction et problématique

2.1 Le contexte scientifique et la motivation du projet

2.2 La problématique ou la question de recherche

2.3 Les objectifs

Offrir aux utilisateurs des outils qui ne sont pas disponibles sur Trex. Offrir aux utilisateurs un site web intuitif pour effectuer des analyses phylogénétiques.

3 Méthodes et matériel

3.1 Les données utilisées

3.2 Les algorithmes, outils et logiciels

3.2.1 Informatique

Nous avons utilisé **Git** pour le contrôle de version et le développement collaboratif. Notre *repository* est hébergé sur GitHub.

Développement backend :

- **Langage** : Nous avons choisi de développer le site Web en Python parce que nous voulions utiliser la bibliothèque BioPython (1). BioPython est un ensemble d'outils de biologie computationnelle et de bioinformatique.
- **Framework** : Pour le *framework*, nous avons utilisé **Flask** pour implémenter la gestion des requêtes et des réponses HTTP.

Développement frontend :

Pour développer l'interface utilisateur, nous avons utilisé les trois langages de base:

- **HTML** : Fournit la base structurelle de l'interface web.
- **CSS** : Définit le style visuel et la présentation de l'application.
- **JavaScript** : Permet de rendre le site dynamique et interactif.

De plus, nous avons essayé de respecter les normes d'accessibilité web afin de garantir que la plateforme soit accessible au plus grand nombre. Nous avons utilisé le WebAIM Contrast Checker pour vérifier que les rapports de contraste *text-to-background* et la taille de la police respectent ou dépassent les normes de WebAIM.

Déploiement :

- **Configuration de l'environnement :**

- **Docker :** Un Dockerfile garantit que toutes les dépendances requises sont installées et configurées de la même manière à chaque exécution, ce qui facilite le déploiement du projet et assure que l'application fonctionne de manière fiable dans n'importe quel environnement, que ce soit en local ou sur un serveur. Notre Dockerfile construit un *container* basé sur Python 3.13, installe et configure les dépendances (MAFFT, Clustal Omega, MrBayes, MUSCLE, IQ-TREE et MPBoot, ainsi que le fichier requirements.txt), puis lance l'application à l'aide de Gunicorn sur le port 8080.
- **requirements.txt :** contient tous les packages Python nécessaires au projet (flask, gunicorn, biopython, matplotlib).

- **Hosting :** Nous hébergeons notre site pour le rendre accessible aux utilisateurs d'Internet. Notre site Web est hébergé sur DigitalOcean. Nous avons enregistré notre nom de domaine via Name.com et choisi DigitalOcean pour l'hébergement, en profitant du GitHub Student Developer Pack, qui nous offrait un nom de domaine gratuit pendant un an et 200 \$ de crédits DigitalOcean.

3.2.2 Phylogénétique

Nous nous sommes concentrés sur la mise à jour des outils actuellement proposés par TREX en intégrant des alternatives plus récentes et en ajoutant une méthode bayésienne pour l'inférence d'arbres.

Inférence d'arbre :

Après chaque méthode d'inférence d'arbre, une visualisation de l'arbre est automatiquement générée pour l'utilisateur. Afin d'offrir une expérience plus interactive, nous avons exploré des outils autres que `Phylo.draw()` et `Phylo.draw_ascii()` de BioPython. Pour ce faire, nous avons implémenté `Phylocanvas.gl` (2), car il propose des fonctionnalités interactives permettant aux utilisateurs d'explorer et de manipuler les arbres phylogénétiques. En plus d'offrir des options similaires à T-REX, notre implémentation permet également d'ajouter des légendes de figures, de appliquer une représentation circulaire de l'arbre et de télécharger celui-ci (Figure 1).




Figure 1: Options PhyloDendron.rocks (gauche) ; Options T-REX (droite)

- **Inférence bayésienne :** Pour l'inférence bayésienne, plutôt que de rechercher un seul arbre optimal, on explore la distribution postérieure des arbres, longueurs de branches et paramètres du modèle. Nous avons utilisé le logiciel MrBayes (3) pour implémenter l'inférence bayésienne en phylogénétique. MrBayes utilise des méthodes de MCMC (Markov Chain Monte Carlo) pour approximer cette distribution a posteriori et estimer les phylogénies et les temps de divergence des espèces (4). Pour construire un arbre de consensus par inférence bayésienne sur notre site Web, l'utilisateur saisit un

fichier de séquences alignées (au format FASTA ou NEXUS) ainsi que les paramètres (number of generations, sample frequency, print frequency et number of burn-ins). Si l'utilisateur entre un fichier FASTA, il est automatiquement converti au format NEXUS. Les paramètres par défaut sont également disponibles (Figure 2). Une fois l'analyse terminée, les arbres de consensus obtenus et les résultats sont compilés dans un fichier ZIP téléchargeable.

The screenshot shows the MrBayes web interface. At the top, there's a section titled 'Upload aligned sequences (FASTA or NEXUS)' with a 'Choose File' button and a note 'no file selected'. Below this is a dropdown menu for inference settings, with 'Fast (100 000 gen)' selected. Underneath is the 'Custom Parameters' section, which includes four input fields: 'Number of Generations' (100000), 'Sample Frequency' (100), 'Print Frequency' (10000), and 'Number of Burn-ins' (250). At the bottom of this section is a purple button labeled 'Run MrBayes'.

Figure 2: Paramètres d'inférence bayésienne

- **Parcimonie :**
- **Maximum de vraisemblance :**
- **Méthodes de distance :** Pour la construction d'arbres par méthodes de distances, l'utilisateur saisit deux entrées : un fichier FASTA aligné et la méthode de distance, NJ ou UPGMA. Contrairement au plateforme T-REX, où le modèle de substitution est sélectionné manuellement par l'utilisateur, nous avons utilisé IQ-TREE (5) afin de sélectionner le modèle de substitution le plus approprié en nous basant sur le critère BIC (Bayesian Information Criterion). Le mot-clé MFP (ModelFinder Plus) indique à IQ-TREE d'effectuer l'analyse en utilisant le modèle qui minimise le score BIC [(6).

```
cmd = ["iqtree3", "-s", filepath, "-m", "MFP", "-nt", "AUTO",
      "-pre", output_prefix, "-redo"]
```

La matrice de distances est générée par IQ-TREE lors de cette sélection de modèle, puis nous la convertissons au format compatible avec Biopython. Enfin, la méthode de distance choisie par l'utilisateur est appliquée à cette matrice pour construire l'arbre phylogénétique, toutes deux implémentées via Biopython (1).

Alignement :

- **MUSCLE :**
- **MAFFT :**
- **Clustal Omega :**

Autre Outils :

- **Viewer d'arbre Newick :**
- **Conversion :**

3.3 Le protocole

4 Résultats et discussion

4.1 Les résultats

4.2 Analyse et interprétation des résultats

4.3 Les forces et les limites

Proposez des perspectives ou des améliorations possibles - Mr Bayes vs Beast - have bayesianinference run in the background

4.4 Comparison

5 Conclusion

6 Références

1. Cock PJA, Antao T, Chang JT, Chapman BA, Cox CJ, Dalke A, et al. Biopython: Freely available python tools for computational molecular biology and bioinformatics. *Bioinformatics* 25 (11), 1422–1423 () [Internet]. 2009; Available from: <https://doi.org/10.1093/bioinformatics/btp163>
2. Abudahab K, Underwood A, Taylor B, Yeats C, Aanensen DM. Phylocanvas.gl: A WebGL-powered JavaScript library for large tree visualisation. 2021; Available from: <https://doi.org/10.31219/osf.io/nfv6m>
3. Ronquist F, Teslenko M, Mark P van der, Ayres DL, Darling A, Höhna S, et al. MrBayes 3.2: Efficient bayesian phylogenetic inference and model choice across a large model space. *Systematic biology*, 61(3), 539–542 [Internet]. 2012; Available from: <https://doi.org/10.1093/sysbio/sys029>
4. Nascimento FF, Reis M dos, 3 ZY. A biologist's guide to bayesian phylogenetic analysis. *Nat Ecol Evol* 1, 1446–1454 [Internet]. 2017; Available from: <https://doi.org/10.1038/s41559-017-0280-x>
5. Nguyen LT, Schmidt HA, Haeseler A von, Minh BQ. IQ-TREE: A fast and effective stochastic algorithm for estimating maximum-likelihood phylogenies. *Molecular biology and evolution*, 32(1), 268–274 [Internet]. 2015; Available from: <https://doi.org/10.1093/molbev/msu300>
6. Hoang DT, Schmidt H, Trifinopoulos J, Bui M. IQ-TREE: Beginner's tutorial. 2023; Available from: <https://iqtree.github.io/doc/Tutorial>
7. Cock PJA, Fields CJ, Goto N, Heuer ML, Rice PM. The sanger FASTQ file format for sequences with quality scores, and the solexa/illumina FASTQ variants. *Nucleic Acids Research* 38 (6): 1767–1771 [Internet]. 2010; Available from: <https://doi.org/10.1093/nar/gkp1137>
8. Sievers F, Wilm A, Dineen D, Gibson TJ, Karplus K, Li W, et al. Fast, scalable generation of high-quality protein multiple sequence alignments using clustal omega. *Molecular systems biology*, 7, 539 [Internet]. 2011; Available from: <https://doi.org/10.1038/msb.2011.75>

9. Gascuel O. BIONJ: An improved version of the NJ algorithm based on a simple model of sequence data. *Molecular biology and evolution*, 14(7), 685–695 [Internet]. 1997; Available from: <https://doi.org/10.1093/oxfordjournals.molbev.a025808>
10. Hoang DT, Vinh LS, Flouri T, Stamatakis A, Haeseler A von, Minh BQ. MPBoot: Fast phylogenetic maximum parsimony tree inference and bootstrap approximation. *BMC evolutionary biology*, 18(1), 11 [Internet]. 2018; Available from: <https://doi.org/10.1186/s12862-018-1131-3>
11. Boc A, Diallo AB, Makarenkov V. T-REX: A web server for inferring, validating and visualizing phylogenetic trees and networks. *Nucleic Acids Research*, Volume 40, Issue W1 [Internet]. 2012; Available from: <https://doi.org/10.1093/nar/gks485>