

Rapport du projet de session

PhyloDendron - Création d'un site web d'inférence d'arbres phylogénétiques

Session Hiver 2026

Date de remise : 06 mai 2026 à 23h59

Enseignant : Dylan Lebatteux

Chelsea Baek et Mariyana Slavova

Table des matières

1	Résumé	1
2	Introduction et problématique	2
2.1	Les objectifs	2
3	Méthodes et matériel	2
3.1	Les algorithmes, outils et logiciels	2
3.2	Le protocole	6
4	Résultats et discussion	10
4.1	Les résultats	10
4.2	Analyse et interprétation des résultats	10
4.3	Les forces et les limites	10
4.4	Comparison	10
5	Conclusion	10
6	Références	10

1 Résumé

Cet article porte sur la création d'un site web d'inférence d'arbres phylogénétiques, nommé **Phylodendron.rocks**. Il couvre les divers outils implémentés pour l'alignement, l'inférence phylogénétique et plus encore (conversion de fichiers, visualisation d'arbres). Les raisons pour lesquelles les outils spécifiques ont

été sélectionnés ainsi que des tests pour confirmer ces choix sont présentés. Le but ultime de ce projet est de faciliter l'analyse phylogénétique pour les utilisateurs, leur offrant un grand éventail de possibilités pour répondre à leurs besoins spécifiques. Ultiment, ce projet nous a permis de nous familiariser avec plusieurs langages de programmation, et d'appliquer les connaissances acquises durant le cours BIF-7101.

2 Introduction et problématique

L'inférence phylogénétique permet d'étudier les relations évolutives entre les organismes vivants en construisant des arbres à partir de données observées, telles que des séquences d'ADN ou de protéines. Il existe diverses méthodes pour l'inférence, telles que des méthodes de distance, de parcimonie et probabilistes. Un obstacle à ce domaine d'étude est le fait de devoir télécharger de nombreux algorithmes avant l'étape de l'analyse. Cela peut grandement ralentir une étude lorsque nous ne sommes pas familier avec l'informatique. C'est pourquoi il existe des sites webs d'inférence d'arbres phylogénétiques. Cependant, nous avons constaté que la plateforme T-rex, créé par Alix Boc, Alpha Boubacar Diallo et Vladimir Makarenkov, qui détermine l'inférence, la validation et la visualisation d'arbres et de réseaux phylogénétiques (1), n'est plus maintenue. En effet, plusieurs méthodes utilisées ont connu des mises à jour qui n'ont pas été reflétées sur le serveur web.

2.1 Les objectifs

L'objectif principal de ce projet est d'offrir aux utilisateurs des outils qui sont à jour et qui ne sont pas disponibles sur T-rex afin qu'ils puissent recevoir de meilleurs résultats, et ce, souvent plus rapidement. Certes, les anciennes versions peuvent encore fonctionner, mais n'offre pas le meilleur potentiel aux données.

Un second objectif est de créer un site web intuitif et facile d'utilisation. Nous voulons que les utilisateurs puissent télécharger les fichiers produits par les outils d'inférence au besoin et de pouvoir visualiser leurs arbres de diverses manières en leur permettant de changer les paramètres désirés.

3 Méthodes et matériel

3.1 Les algorithmes, outils et logiciels

3.1.1 Informatique

Nous avons utilisé **Git** pour le contrôle de version et le développement collaboratif. Notre *repository* est hébergé sur GitHub.

Développement backend :

- **Langage** : Nous avons choisi de développer le site Web en Python parce que nous voulions utiliser la bibliothèque BioPython (2). BioPython est un ensemble d'outils de biologie computationnelle et de bioinformatique.
- **Framework** : Pour le *framework*, nous avons utilisé **Flask** pour implémenter la gestion des requêtes et des réponses HTTP.

Développement frontend :

Pour développer l'interface utilisateur, nous avons utilisé les trois langages de base:

- **HTML** : Fournit la base structurelle de l'interface web.

- **CSS** : Définit le style visuel et la présentation de l'application.
- **JavaScript** : Permet de rendre le site dynamique et interactif.

De plus, nous avons essayé de respecter les normes d'accessibilité web afin de garantir que la plateforme soit accessible au plus grand nombre. Nous avons utilisé le WebAIM Contrast Checker pour vérifier que les rapports de contraste *text-to-background* et la taille de la police respectent ou dépassent les normes de WebAIM.

Déploiement :

- **Configuration de l'environnement** :
 - **Docker** : Un Dockerfile garantit que toutes les dépendances requises sont installées et configurées de la même manière à chaque exécution, ce qui facilite le déploiement du projet et assure que l'application fonctionne de manière fiable dans n'importe quel environnement, que ce soit en local ou sur un serveur. Notre Dockerfile construit un *container* basé sur Python 3.13, installe et configure les dépendances (MAFFT, Clustal Omega, MrBayes, MUSCLE, IQ-TREE et MPBoot, ainsi que le fichier requirements.txt), puis lance l'application à l'aide de Gunicorn sur le port 8080.
 - **requirements.txt** : contient tous les packages Python nécessaires au projet (**flask**, **gunicorn**, **biopython**, **matplotlib**).
- **Hosting** : Nous hébergeons notre site pour le rendre accessible aux utilisateurs d'Internet. Notre site Web est hébergé sur DigitalOcean. Nous avons enregistré notre nom de domaine via Name.com et choisi DigitalOcean pour l'hébergement, en profitant du GitHub Student Developer Pack, qui nous offrait un nom de domaine gratuit pendant un an et 200 \$ de crédits DigitalOcean.

3.1.2 Phylogénétique

Nous nous sommes concentrés sur la mise à jour des outils actuellement proposés par TREX en intégrant des alternatives plus récentes et en ajoutant une méthode bayésienne pour l'inférence d'arbres.

Inférence d'arbre :

Après chaque méthode d'inférence d'arbre, une visualisation de l'arbre est automatiquement générée pour l'utilisateur. Afin d'offrir une expérience plus interactive, nous avons exploré des outils autres que `Phylo.draw()` et `Phylo.draw_ascii()` de BioPython. Pour ce faire, nous avons implémenté `Phylocanvas.gl` (3), car il propose des fonctionnalités interactives permettant aux utilisateurs d'explorer et de manipuler les arbres phylogénétiques. En plus d'offrir des options similaires à T-REX, notre implémentation permet également d'ajouter des légendes de figures, de appliquer une représentation circulaire de l'arbre et de télécharger celui-ci (Figure 1).




Figure 1: Options PhyloDendron.rocks (gauche) ; Options T-REX (droite)

- **Inférence bayésienne** : Pour l'inférence bayésienne, plutôt que de rechercher un seul arbre optimal, on explore la distribution postérieure des arbres, longueurs de branches et paramètres du modèle. Nous avons utilisé le logiciel MrBayes (4) pour implémenter l'inférence bayésienne en phylogénétique. MrBayes utilise des méthodes de MCMC (Markov Chain Monte Carlo) pour approximer cette distribution a posteriori et estimer les phylogénies et les temps de divergence des espèces (5). Pour construire un arbre de consensus par inférence bayésienne sur notre site Web, l'utilisateur saisit un fichier de séquences alignées (au format FASTA ou NEXUS) ainsi que les paramètres (number of generations, sample frequency, print frequency et number of burn-ins). Si l'utilisateur entre un fichier FASTA, il est automatiquement converti au format NEXUS. Les paramètres par défaut sont également disponibles (Figure 2). Une fois l'analyse terminée, les arbres de consensus obtenus et les résultats sont compilés dans un fichier ZIP téléchargeable.

Upload aligned sequences (FASTA or NEXUS)

Choose File no file selected

Intensive (1 000 000 gen)
 ✓ Fast (100 000 gen)
 Custom (Manual Entry)

Custom Parameters

Number of Generations: 100000

Sample Frequency: 100

Print Frequency: 10000

Number of Burn-ins: 250

Run MrBayes

Figure 2: Paramètres d'inférence bayésienne

- **Parcimonie** : Pour l'inférence par méthode de parcimonie, nous avons décidé d'implémenter l'outil MPBoot (6) qui n'est pas disponible sur la plateforme T-rex. Ce programme permet également de faire une approximation rapide des bootstraps de parcimonie maximale (UFBoot, inspiré des méthodes similaires employées pour celles de maximum de vraisemblance). Il n'est donc pas nécessaire d'utiliser un outil supplémentaire (ex: SeqBoot) si le calcul des bootstraps est désiré. Pour l'algorithme de recherche, il utilise le réarrangement SPR et implémente le Parsimony ratchet. Cet algorithme blabla. Sur notre plateforme, l'utilisateur télécharge ses séquences alignées en format FASTA et choisit les valeurs des paramètres suivant:
 - Ultrafast Bootstraps:
 - SPR Radius: Indique le rayon de SPR. Un rayon plus grand permet à l'algorithme de déplacer des branches plus loin dans l'arbre, ce qui augmente la possibilité de trouver un optimum global (mais augmente le temps de computation).
 - Ratchet Iterations:
 - Ratchet %:
 - Use NNI instead of SPR: Utile lorsqu'une analyse plus rapide est désirée, mais produit un résultat moins stricte et minutueux. Les paramètres par défaut sont aussi disponibles afin de faciliter la tâche aux utilisateurs (Figure 3). À la fin de l'analyse, plusieurs fichiers informatifs sont disponibles pour le téléchargement (Figure 4).

Maximum Parsimony (MPBoot)
Construct phylogenetic trees using fast maximum parsimony with bootstrap replicates.

Upload aligned sequences (FASTA)

Choose File | No file chosen

Suggested Presets:
Standard (Default Balance)

Parameters

Ultrafast Bootstraps 1000	SPR Radius 6
Ratchet Iterations 1	Ratchet % 50
☐ Use NNI instead of SPR	☐ Store Multiple Hits (-multis)

[Generate Parsimony Tree](#)

Figure 3: Paramètres d'inférence par MPBoot



Figure 4: Fichiers téléchargeables disponibles

- **Maximum de vraisemblance :** Quant à l'inférence par maximum de vraisemblance, l'outil IQTREE (7) à été utilisé (non disponible sur T-rex).
- **Méthodes de distance :** Pour la construction d'arbres par méthodes de distances, l'utilisateur saisit deux entrées : un fichier FASTA aligné et la méthode de distance, NJ ou UPGMA. Contrairement au plateforme T-REX, où le modèle de substitution est sélectionné manuellement par l'utilisateur, nous avons utilisé IQ-TREE (7) afin de sélectionner le modèle de substitution le plus approprié en nous basant sur le critère BIC (Bayesian Information Criterion). Le mot-clé MFP (ModelFinder Plus) indique à IQ-TREE d'effectuer l'analyse en utilisant le modèle qui minimise le score BIC [(8).

```
cmd = ["iqtree3", "-s", filepath, "-m", "MFP", "-nt", "AUTO",
      "-pre", output_prefix, "-redo"]
```

La matrice de distances est générée par IQ-TREE lors de cette sélection de modèle, puis nous la convertissons au format compatible avec Biopython. Enfin, la méthode de distance choisie par l'utilisateur est appliquée à cette matrice pour construire l'arbre phylogénétique, toutes deux implémentées via Biopython (2).

Alignement :

- **MUSCLE :**
- **MAFFT :**
- **Clustal Omega :**

Autre Outils :

- **Viewer d'arbre Newick :**
- **Conversion :**

3.2 Le protocole

Cette section porte sur des tests effectués afin de valider l'implémentation des nouveaux outils (ClustalO, MPBoot, IQTREE et MrBayes) en les comparant avec un outil semblable disponible sur T-rex.

3.2.1 Jeux de données

Afin de tester les outils, plusieurs séquences de référence ont été téléchargées de la base BaliBase.

3.2.2 Tester ClustalO

Pourquoi implémenter ClustalO au lieu de ClustalW?

ClustalO utilise des HMM pour l'alignement profil-profil -> permet d'obtenir une meilleure précision, notamment pour les relations phylogénétiques éloignées.

ClustalW utilise une stratégie d'alignement progressif avec pondération des séquences.

Test case: Benchmark references BaliBase3 -> run clustalO et clustalW sur les references de BaliBase3 et appliquer iqtree3 aux résultats pour démontrer que clustalO produit un meilleur alignement de séquences.




Table 1: Log-Likelihood Comparison: ClustalO vs ClustalW

DataSet	LogL ClustalO	LogL ClustalW	Difference $\Delta \ln L$
BB11001	-886.8577	-880.2027	-6.6550
BB11002	-2092.8031	-2138.9514	46.1483
BB11003	-5030.4580	-5098.8827	68.4247
BB11004	-4615.6993	-4774.8269	159.1276
BB11005	-14630.4153	-15165.8266	535.4113
BB11006	-5282.8166	-5417.3120	134.4954
BB11007	-9765.0703	-9922.5041	157.4338
BB11008	-3375.1971	-3430.4828	55.2857
BB11009	-2361.1142	-2434.4417	73.3275
BB11010	-5296.4244	-5418.3610	121.9366
BB11011	-2731.2691	-2820.7413	89.4722
BB11012	-3770.0699	-3763.0219	-7.0480
BB11013	-969.4768	-968.2593	-1.2175
BB11014	-8314.4902	-8452.9537	138.4635
BB11015	-3234.5981	-3292.1999	57.6018
BB11016	-10039.5630	-10247.2661	207.7031
BB11017	-2598.3897	-2626.9057	28.5160
BB11018	-20003.4046	-20760.0193	756.6147
BB11019	-8899.0217	-9146.2204	247.1987
BB11020	-5153.3726	-5210.8447	57.4721
BB11021	-1233.8427	-1282.9823	49.1396
BB11022	-1276.6726	-1300.0592	23.3866
BB11023	-5638.6468	-5831.1325	192.4857
BB11024	-4456.0704	-4588.0246	131.9542
BB11025	-923.0119	-931.2419	8.2300
BB11026	-4657.8646	-4714.7125	56.8479
BB11027	-4284.2234	-4439.6467	155.4233
BB11028	-4216.0853	-4296.8722	80.7869
BB11029	-1086.7838	-1078.2361	-8.5477
BB11030	-10651.6158	-11165.8629	514.2471
BB11031	-11133.2634	-11543.2571	409.9937
BB11032	-6286.5781	-6418.5129	131.9348
BB11033	-4408.0949	-4510.4079	102.3130
BB11034	-10452.9627	-10742.5782	289.6155
BB11035	-1290.1666	-1258.5651	-31.6015
BB11036	-7776.1299	-7950.9448	174.8149
BB11037	-7235.1302	-7380.3570	145.2268
BB11038	-7586.3363	-7857.6230	271.2867

3.2.3 Tester MPBoot

Ici, nous reprenons les alignements de séquences générés par ClustalO. Nous appliquons ensuite MPBoot et PROTPARS à chacun de ces alignements.

Table 2: Parsimony Score Comparison: MPBoot vs PROTPARS

DataSet	MPBoot score	PROTPARS score	Difference Δ Score
BB11001	173	294	121
BB11002	339	1443	1104
BB11003	909	1989	1080
BB11004	751	2295	1544
BB11005	3239	6799	3560
BB11006	1018	2772	1754
BB11007	2090	3981	1891
BB11008	435	2381	1946
BB11009	295	1768	1473
BB11010	917	2334	1417
BB11011	495	1707	1212
BB11012	702	1365	663
BB11013	172	665	493
BB11014	1636	3090	1454
BB11015	612	1089	477
BB11016	1840	5492	3652
BB11017	470	967	497
BB11018	4184	11724	7540
BB11019	1896	3712	1816
BB11020	1113	2233	1120
BB11021	193	653	460
BB11022	183	897	714
BB11023	1152	2590	1438
BB11024	667	2772	2105
BB11025	159	488	329
BB11026	536	3785	3249
BB11027	780	2288	1508
BB11028	910	2004	1094
BB11029	184	508	324
BB11030	2311	5370	3059
BB11031	2156	6697	4541
BB11032	1221	3009	1788
BB11033	861	2638	1777
BB11034	1956	5607	3651
BB11035	225	651	426
BB11036	1614	3673	2059
BB11037	950	4717	3767
BB11038	1423	3904	2481

3.2.4 Tester IQTREE

Table 3: LogL Score and Time Comparison: IQTREE vs RAXML

DataSet	IQTREE LogL	RAXML LogL	IQTREE Time	RAXML Time	Difference Δ Time
BB11001	-932.7975	-932.8367	32.62	1.71	-30.91
BB11002	-2093.2598	-2093.2660	40.27	94.62	54.35
BB11003	-5030.4587	-5030.4868	45.63	9.29	-36.34
BB11004	-4615.7059	-4615.7178	43.39	9.99	-33.40
BB11005	-14634.6412	-14634.6442	55.90	643.54	587.64
BB11006	-5298.2923	-5298.3009	38.17	121.07	82.90
BB11007	-9776.0245	-9776.0287	43.96	213.39	169.43
BB11008	-3382.2207	-3382.2530	38.41	9.65	-28.76
BB11009	-2370.9981	-2371.0654	41.16	8.21	-32.95
BB11010	-5304.0617	-5304.1195	38.13	10.39	-27.74
BB11011	-2747.4402	-2747.4484	37.40	30.54	-6.86
BB11012	-3770.8745	-3770.8894	36.34	10.04	-26.30
BB11013	-968.7549	-968.8047	37.97	11.98	-25.99
BB11014	-8314.7669	-8314.7739	37.69	104.08	66.39
BB11015	-3234.1104	-3234.1313	40.26	4.88	-35.38
BB11016	-10053.8613	-10053.8790	47.11	222.40	175.29
BB11017	-2606.1492	-2606.1662	36.28	8.74	-27.54
BB11018	-20238.2488	-20238.2508	66.40	1122.04	1055.64
BB11019	-8933.7061	-8933.7157	40.41	212.77	172.36
BB11020	-5153.3728	-5153.3797	35.89	120.14	84.25
BB11021	-1246.1784	-1246.2185	35.32	4.02	-31.30
BB11022	-1276.5000	-1276.5200	34.37	4.20	-30.17
BB11023	-5733.0518	-5733.0598	38.59	103.81	65.22
BB11024	-4453.3528	-4453.3809	32.82	8.50	-24.32
BB11025	-922.3562	-922.3866	36.09	2.67	-33.42
BB11026	-4677.8854	-4677.9280	35.28	133.31	98.03
BB11027	-4284.2235	-4284.2346	36.98	56.31	19.33
BB11028	-4231.7223	-4231.7431	35.80	174.71	138.91
BB11029	-1096.6443	-1096.6787	34.13	2.11	-32.02
BB11030	-10668.7914	-10668.7979	46.76	609.87	563.11
BB11031	-11255.5932	-11255.5986	41.61	424.34	382.73
BB11032	-6290.1084	-6290.1134	35.54	140.79	105.25
BB11033	-4422.3110	-4422.3248	37.97	207.37	169.40
BB11034	-10471.3425	-10471.3600	41.27	188.15	146.88
BB11035	-1306.1514	-1306.1878	30.88	16.29	-14.59
BB11036	-7791.1178	-7791.1329	35.25	168.84	133.59
BB11037	-7277.8673	-7277.8861	38.81	40.96	2.15
BB11038	-7586.3357	-7586.3420	38.53	173.47	134.94

4 Résultats et discussion

4.1 Les résultats

4.2 Analyse et interprétation des résultats

4.3 Les forces et les limites

Proposez des perspectives ou des améliorations possibles - Mr Bayes vs Beast - have bayesianinference run in the background

4.4 Comparison

5 Conclusion

6 Références

1. Boc A, Diallo AB, Makarenkov V. T-REX: A web server for inferring, validating and visualizing phylogenetic trees and networks. *Nucleic Acids Research*, Volume 40, Issue W1 [Internet]. 2012; Available from: <https://doi.org/10.1093/nar/gks485>
2. Cock PJA, Antao T, Chang JT, Chapman BA, Cox CJ, Dalke A, et al. Biopython: Freely available python tools for computational molecular biology and bioinformatics. *Bioinformatics* 25 (11), 1422–1423 () [Internet]. 2009; Available from: <https://doi.org/10.1093/bioinformatics/btp163>
3. Abudahab K, Underwood A, Taylor B, Yeats C, Aanensen DM. Phyloanvas.gl: A WebGL-powered JavaScript library for large tree visualisation. 2021; Available from: <https://doi.org/10.31219/osf.io/nfv6m>
4. Ronquist F, Teslenko M, Mark P van der, Ayres DL, Darling A, Höhna S, et al. MrBayes 3.2: Efficient bayesian phylogenetic inference and model choice across a large model space. *Systematic biology*, 61(3), 539–542 [Internet]. 2012; Available from: <https://doi.org/10.1093/sysbio/sys029>
5. Nascimento FF, Reis M dos, 3 ZY. A biologist’s guide to bayesian phylogenetic analysis. *Nat Ecol Evol* 1, 1446–1454 [Internet]. 2017; Available from: <https://doi.org/10.1038/s41559-017-0280-x>
6. Hoang DT, Vinh LS, Flouri T, Stamatakis A, Haeseler A von, Minh BQ. MPBoot: Fast phylogenetic maximum parsimony tree inference and bootstrap approximation. *BMC evolutionary biology*, 18(1), 11 [Internet]. 2018; Available from: <https://doi.org/10.1186/s12862-018-1131-3>
7. Nguyen LT, Schmidt HA, Haeseler A von, Minh BQ. IQ-TREE: A fast and effective stochastic algorithm for estimating maximum-likelihood phylogenies. *Molecular biology and evolution*, 32(1), 268–274 [Internet]. 2015; Available from: <https://doi.org/10.1093/molbev/msu300>
8. Hoang DT, Schmidt H, Trifinopoulos J, Bui M. IQ-TREE: Beginner’s tutorial. 2023; Available from: <https://iqtree.github.io/doc/Tutorial>
9. Cock PJA, Fields CJ, Goto N, Heuer ML, Rice PM. The sanger FASTQ file format for sequences with quality scores, and the solexa/illumina FASTQ variants. *Nucleic Acids Research* 38 (6): 1767–1771 [Internet]. 2010; Available from: <https://doi.org/10.1093/nar/gkp1137>
10. Sievers F, Wilm A, Dineen D, Gibson TJ, Karplus K, Li W, et al. Fast, scalable generation of high-quality protein multiple sequence alignments using clustal omega. *Molecular systems biology*, 7, 539 [Internet]. 2011; Available from: <https://doi.org/10.1038/msb.2011.75>
11. Gascuel O. BIONJ: An improved version of the NJ algorithm based on a simple model of sequence data. *Molecular biology and evolution*, 14(7), 685–695 [Internet]. 1997; Available from: <https://doi.org/10.1093/oxfordjournals.molbev.a025808>