

Rapport du projet de session

PhyloDendron - Création d'un site web d'inférence d'arbres phylogénétiques

Session Hiver 2026

Date de remise : 06 mai 2026 à 23h59

Enseignant : Dylan Lebatteux

Chelsea Baek et Mariyana Slavova

Table des matières

1	Résumé	2
2	Introduction et problématique	2
2.1	Les objectifs	2
3	Méthodes et matériel	2
3.1	Les algorithmes, outils et logiciels	2
3.2	Le protocole	6
4	Résultats et discussion	7
4.1	Les résultats	7
4.2	Analyse et interprétation des résultats	8
4.3	Les forces et les limites	8
5	Conclusion	8
6	Références	9

1 Résumé

Cet article porte sur la création d'un site web d'inférence d'arbres phylogénétiques, nommé **Phylodendron.rocks**. Il couvre les divers outils implémentés pour l'alignement, l'inférence phylogénétique et plus encore (conversion de fichiers, visualisation d'arbres). Les raisons pour lesquelles les outils spécifiques ont été sélectionnés ainsi que des tests pour confirmer ces choix sont présentés. Le but ultime de ce projet est de faciliter l'analyse phylogénétique pour les utilisateurs, leur offrant un grand éventail de possibilités pour répondre à leurs besoins spécifiques. Sur le plan personnel, ce projet nous a permis de nous familiariser avec plusieurs langages de programmation, et d'appliquer les connaissances acquises durant le cours BIF-7101.

2 Introduction et problématique

L'inférence phylogénétique permet d'étudier les relations évolutives entre les organismes vivants en construisant des arbres à partir de données observées, telles que des séquences d'ADN ou de protéines. Il existe diverses méthodes pour l'inférence, telles que des méthodes de distance, de parcimonie et probabilistes. Un obstacle à ce domaine d'étude est le fait de devoir télécharger de nombreux algorithmes avant l'étape de l'analyse. Cela peut grandement ralentir une étude lorsque nous ne sommes pas familier avec l'informatique. C'est pourquoi il existe des sites webs d'inférence d'arbres phylogénétiques. Cependant, nous avons constaté que la plateforme T-rex, créé par Alix Boc, Alpha Boubacar Diallo et Vladimir Makarenkov, qui détermine l'inférence, la validation et la visualisation d'arbres et de réseaux phylogénétiques (1), n'est plus maintenue. En effet, plusieurs méthodes utilisées ont connu des mises à jour qui n'ont pas été reflétées sur le serveur web.

2.1 Les objectifs

L'objectif principal de ce projet est d'offrir aux utilisateurs des outils qui sont à jour et qui ne sont pas disponibles sur T-rex afin qu'ils puissent recevoir de meilleurs résultats, et ce, souvent plus rapidement. Certes, les anciennes versions peuvent encore fonctionner, mais n'offrent pas le meilleur potentiel aux données.

Un second objectif est de créer un site web intuitif et facile d'utilisation. Nous voulons que les utilisateurs puissent télécharger les fichiers produits par les outils d'inférence au besoin et de pouvoir visualiser leurs arbres de diverses manières en leur permettant de changer les paramètres désirés.

3 Méthodes et matériel

3.1 Les algorithmes, outils et logiciels

3.1.1 Informatique

Nous avons utilisé **Git** pour le contrôle de version et le développement collaboratif. Notre *repository* est hébergé sur GitHub.

Développement backend :

- **Langage** : Nous avons choisi de développer le site Web en Python parce que nous voulions utiliser la bibliothèque BioPython (2). BioPython est un ensemble d'outils de biologie computationnelle et de bioinformatique.

- **Framework** : Pour le *framework*, nous avons utilisé **Flask** pour implémenter la gestion des requêtes et des réponses HTTP.

Développement frontend :

Pour développer l'interface utilisateur, nous avons utilisé les trois langages de base:

- **HTML** : Fournit la base structurelle de l'interface web.
- **CSS** : Définit le style visuel et la présentation de l'application.
- **JavaScript** : Permet de rendre le site dynamique et interactif.

De plus, nous avons essayé de respecter les normes d'accessibilité web afin de garantir que la plateforme soit accessible au plus grand nombre. Nous avons utilisé le WebAIM Contrast Checker pour vérifier que les rapports de contraste *text-to-background* et la taille de la police respectent ou dépassent les normes de WebAIM.

Déploiement :

- **Configuration de l'environnement** :
 - **Docker** : Un Dockerfile garantit que toutes les dépendances requises sont installées et configurées de la même manière à chaque exécution, ce qui facilite le déploiement du projet et assure que l'application fonctionne de manière fiable dans n'importe quel environnement, que ce soit en local ou sur un serveur. Notre Dockerfile construit un *container* basé sur Python 3.13, installe et configure les dépendances (MAFFT, Clustal Omega, MrBayes, MUSCLE, IQ-TREE et MPBoot, ainsi que le fichier requirements.txt), puis lance l'application à l'aide de Gunicorn sur le port 8080.
 - **requirements.txt** : contient tous les packages Python nécessaires au projet (flask, gunicorn, biopython, matplotlib).
- **Hosting** : Nous hébergeons notre site pour le rendre accessible aux utilisateurs d'Internet. Notre site Web est hébergé sur DigitalOcean. Nous avons enregistré notre nom de domaine via Name.com et choisi DigitalOcean pour l'hébergement, en profitant du GitHub Student Developer Pack, qui nous offrait un nom de domaine gratuit pendant un an et 200 \$ de crédits DigitalOcean.

3.1.2 Phylogénétique

Nous nous sommes concentrés sur la mise à jour des outils actuellement proposés par TREX en intégrant des alternatives plus récentes et en ajoutant une méthode bayésienne pour l'inférence d'arbres.

Inférence d'arbre :

Après chaque méthode d'inférence d'arbre, une visualisation de l'arbre est automatiquement générée pour l'utilisateur. Afin d'offrir une expérience plus interactive, nous avons exploré des outils autres que `Phylo.draw()` et `Phylo.draw_ascii()` de BioPython. Pour ce faire, nous avons implémenté Phylocanvas.gl (3), car il propose des fonctionnalités interactives permettant aux utilisateurs d'explorer et de manipuler les arbres phylogénétiques. En plus d'offrir des options similaires à T-REX, notre implémentation permet également d'ajouter des légendes de figures, de appliquer une représentation circulaire de l'arbre et de télécharger celui-ci (Figure 1).




Figure 1: Options PhyloDendron.rocks (gauche) ; Options T-REX (droite)

- **Inférence bayésienne** : Pour l'inférence bayésienne, plutôt que de rechercher un seul arbre optimal, on explore la distribution postérieure des arbres, longueurs de branches et paramètres du modèle. Nous avons utilisé le logiciel MrBayes (4) pour implementer l'inférence bayésienne en phylogénétique. MrBayes utilise des méthodes de MCMC (Markov Chain Monte Carlo) pour approximer cette distribution a posteriori et estimer les phylogénies et les temps de divergence des espèces (5). Pour construire un arbre de consensus par inférence bayésienne sur notre site Web, l'utilisateur saisit un fichier de séquences alignées (au format FASTA ou NEXUS) ainsi que les paramètres (number of generations, sample frequency, print frequency et number of burn-ins). Si l'utilisateur entre un fichier FASTA, il est automatiquement converti au format NEXUS. Les paramètres par défaut sont également disponibles (Figure 2). Une fois l'analyse terminée, les arbres de consensus obtenus et les résultats sont compilés dans un fichier ZIP téléchargeable.

The image shows a web form for uploading aligned sequences and setting parameters for Bayesian inference. At the top, it says 'Upload aligned sequences (FASTA or NEXUS)' with a 'Choose File' button and 'no file selected' text. Below this is a dropdown menu with three options: 'Intensive (1 000 000 gen)', 'Fast (100 000 gen)' (which is selected), and 'Custom (Manual Entry)'. Underneath is a section titled 'Custom Parameters' with four input fields: 'Number of Generations' (100000), 'Sample Frequency' (100), 'Print Frequency' (10000), and 'Number of Burn-ins' (250). At the bottom left of this section is a 'Run MrBayes' button.

Figure 2: Paramètres d'inférence bayésienne

- **Parcimonie** : Pour l'inférence par méthode de parcimonie, nous avons décidé d'implémenter l'outil MPBoot (6) qui n'est pas disponible sur la plateforme T-rex. Ce programme permet également de faire une approximation rapide des bootstraps de parcimonie maximale (UFBoot, inspiré des méthodes similaires employées pour celles de maximum de vraisemblance). Il n'est donc pas nécessaire d'utiliser un outil supplémentaire (ex: SeqBoot) si le calcul des bootstraps est désiré. Pour l'algorithme de recherche, il utilise le réarrangement SPR et implémente le Parsimony ratchet. Cet algorithme permet de trouver les arbres phylogenetiques les plus parcimonieux en effectuant plusieurs cycles d'échantillonnage et de pondération des sites pour ensuite réaliser des réarrangement des branches en utilisant la méthode SPR. (7). Sur notre plateforme, l'utilisateur télécharge ses séquences alignées en format FASTA et choisit les valeurs des paramètres suivant:

- Ultrafast Bootstraps:
- SPR Radius: Indique le rayon de SPR. Un rayon plus grand permet à l'algorithme de déplacer des branches plus loin dans l'arbre, ce qui augmente la possibilité de trouver un optimum global (mais augmente le temps de computation).
- Ratchet Iterations:
- Ratchet %:
- Use NNI instead of SPR: Utile lorsqu'une analyse plus rapide est désirée, mais produit un résultat moins stricte et minutueux.

Les paramètres par défaut sont aussi disponibles afin de faciliter la tâche aux utilisateurs (Figure 3). À la fin de l'analyse, plusieurs fichiers informatifs sont disponibles pour le téléchargement (Figure 4).

Figure 3: Paramètres d'inférence par MPBoot



Figure 4: Fichiers téléchargeables disponibles

- **Maximum de vraisemblance** : Quant à l'inférence par maximum de vraisemblance, l'outil IQTREE (v3.1.1) (8) à été utilisé (non disponible sur T-rex).
- **Méthodes de distance** : Pour la construction d'arbres par méthodes de distances, l'utilisateur saisit deux entrées : un fichier FASTA aligné et la méthode de distance, NJ ou UPGMA. Contrairement au plateforme T-REX, où le modèle de substitution est sélectionné manuellement par l'utilisateur, nous avons utilisé IQ-TREE (8) afin de sélectionner le modèle de substitution le plus approprié en nous basant sur le critère BIC (Bayesian Information Criterion). Le mot-clé MFP (ModelFinder Plus) indique à IQ-TREE d'effectuer l'analyse en utilisant le modèle qui minimise le score BIC [(9).

```
cmd = ["iqtree3", "-s", filepath, "-m", "MFP", "-nt", "AUTO",
      "-pre", output_prefix, "-redo"]
```

La matrice de distances est générée par IQ-TREE lors de cette sélection de modèle, puis nous la convertissons au format compatible avec Biopython. Enfin, la méthode de distance choisie par l'utilisateur est appliquée à cette matrice pour construire l'arbre phylogénétique, toutes deux implémentées via Biopython (2).

Alignement :

- **MUSCLE :**
- **MAFFT :**
- **Clustal Omega :** ClustalO utilise des HMM pour l'alignement profil-profil ce qui lui permet d'obtenir une meilleure précision, notamment pour les relations phylogénétiques éloignées. En revanche, ClustalW, son predecesseur, utilise une stratégie d'alignement progressif avec pondération des séquences. En effet, Clustal suit $O(n \log n)$ alors que CLustalW suit $O(n^2)$, ce qui demontre qu'avec un plus grand nombre de sequence, ClustalO est plus rapide. ClustalO a aussi remplace complete-ment ClustalW, ce dernier ne recevant plus de mises a jour, ni de support. *something about threads as well* Il est donc important pour nous d'implementer des outils actuels afin de non seulement augmenter la precision des resultats, mais aussi de pouvoir avoir acces a du soutien si un probleme survient.

Autre Outils :

- **Viewer d'arbre Newick :**
- **Conversion :**

3.2 Le protocole

Cette section porte sur des tests effectués afin de valider l'implémentation des nouveaux outils (ClustalO, MPBoot, IQTREE et MrBayes) en les comparant avec un outil semblable disponible sur T-rex.

3.2.1 Jeux de données

Afin de tester les outils, plusieurs groupes de séquences d'acides amines de référence ont été téléchargées de la base de donnees BaliBASE (Benchmark Alignment dataBASE). Cette base de donnees est un reper-toire utilise frequemment pour tester des outils d'alignement de sequence multiples (10). Nous allons donc l'employer d'abord pour evaluer la performance de ClustalO, et ensuite utiliser ces memes resultats d'alignement pour l'evaluation les autres outils phylogenetiques. Ce qui distingue principalement ce jeu de donnees est le fait que les sequences comportent une identite de sequence tres basse (moins de 25%), offrant alors un vrai test de stress a nos outils.

3.2.2 Tester ClustalO

Pour tester la performance de ClustalO contre son predecesseur ClustalW, nous avons voulu calculer le temps d'exécution et la qualité de l'alignement. Pour le test le vitesse, ClustalO et CLustalW ont ete execute a 5 reprises sur 3 groupes de sequences de taille differente (261, 1044, 2088) prises de BaliBASE, et la moyenne du temps a ete retenue pour chaque groupe.

Pour le test de qualité de l'alignement, les alignements produits par ClustalO et ClustalW ont ete appliques sur IQTREE3 et les resultats du score de maximum de vraisemblance de l'arbre optimal generé de chacun a ete comparé. Le meilleur alignement sera donc celui avec le score de maximum de vraisemblance le plus bas.

3.2.3 Tester MPBoot

Afin de tester la performance de MPBoot, nous avons décidé de le comparer à un des algorithmes de maximum de parcimonie disponible sur T-rex. PROTPARS de la suite Phylips a été choisi. Il est spécifiquement programmé pour l'analyse de séquence d'acides aminés. Les alignements de séquences générés par ClustalO à l'étape précédente sont repris, puis sont téléchargés dans MPBoot et PROTPARS. Notez que PROTPARS n'acceptent que les fichiers Phylips, donc nous les avons convertis à l'aide de l'outil de conversion disponible sur **Phylodendron.rocks**. Puisque ces deux algorithmes performant très rapidement (moins de 1 seconde par groupe de séquence dans notre jeu de données), seulement le score de parcimonie de chacun a été comparé.

3.2.4 Tester IQTREE

4 Résultats et discussion

4.1 Les résultats

4.1.1 ClustalO

Test de vitesse :

Le Figure 5 ci dessous demontre que, en augmentant le nombre de sequence, ClustalO performe mieux que ClustalW.




Figure 5: Moyenne du temps d'exécution de CLustalO et ClustalW sur 3 groupes de sequences de taille differente

Test de la qualité de l'alignement :

Le tableau ci dessous demontre que ClustalO effectue un meilleur alignement que ClustalW, echouant seulement 4 fois sur 38.

4.1.2 MPBoot

4.1.3 IQTREE

4.1.4 MrBayes

4.2 Analyse et interprétation des résultats

4.3 Les forces et les limites

Proposez des perspectives ou des améliorations possibles - Mr Bayes vs Beast - have bayesianinference run in the background

5 Conclusion

L'objectif principal de ce projet était de fournir aux utilisateurs une plateforme Web moderne pour l'inférence phylogénétique, intégrant des outils récents non disponibles sur la plateforme T-REX, tout en améliorant la facilité d'utilisation.

L'utilisabilité est améliorée grâce à l'intégration de paramètres prédéfinis suggérés. De plus, les arbres inférés sont automatiquement générés et affichés à la fin de chaque analyse, donc aucun outil supplémentaire n'est nécessaire pour visualiser l'arbre.

PhyloDendron constitue une extension de T-REX dans plusieurs domaines (résumé dans le table 1). Pour l'inférence d'arbres phylogénétiques, l'intégration d'IQ-TREE, MPBoot et MrBayes permet aux utilisateurs d'accéder à ces méthodes (non disponibles sur T-REX). Pour l'alignement de séquences, des outils tels que MUSCLE, MAFFT et ClustalO offrent des alignements plus rapides et plus précis que les versions précédentes, notamment pour les grands ensembles de données. Enfin, nous permettons aux utilisateurs de télécharger des fichiers Newick pour la visualisation et de convertir des fichiers.

working on Proposez des perspectives ou des améliorations possibles

Table 1: Résumé des outils utilisés

Catégorie	Méthode	PhyloDendron	TREX
Inférence d'arbre	Inférence bayésienne	Utilise MrBayes pour estimer les phylogénies des espèces et les temps de divergence	Pas disponible
	Parcimonie	MPBoot ;	
	Maximum de vraisemblance	IQTREE ;	
	Méthodes de distance	Choisit automatiquement le meilleur modèle de substitution selon le BIC	Les utilisateurs saisissent leur choix de modèle de substitution
Alignement	MUSCLE	MUSCLE v5 ; plus précis et plus rapide (utilise multithreading) que v3	MUSCLE v3
	MAFFT	MAFFT v7	MAFFT v6
	Clustal	ClustalO ; plus rapide pour les séquences plus longues	ClustalW ; plus rapide pour les séquences plus courtes
Autres outils	Viewer d'arbre Newick	Plus d'options pour manipuler l'arbre que T-REX	Options pour manipuler l'arbre
	Conversion	Conversion entre différents types de fichiers	Pas disponible

6 Références

1. Boc A, Diallo AB, Makarenkov V. T-REX: A web server for inferring, validating and visualizing phylogenetic trees and networks. *Nucleic Acids Research*, Volume 40, Issue W1 [Internet]. 2012; Available from: <https://doi.org/10.1093/nar/gks485>
2. Cock PJA, Antao T, Chang JT, Chapman BA, Cox CJ, Dalke A, et al. Biopython: Freely available python tools for computational molecular biology and bioinformatics. *Bioinformatics* 25 (11), 1422–1423 () [Internet]. 2009; Available from: <https://doi.org/10.1093/bioinformatics/btp163>
3. Abudahab K, Underwood A, Taylor B, Yeats C, Aanensen DM. Phylocanvas.gl: A WebGL-powered JavaScript library for large tree visualisation. 2021; Available from: <https://doi.org/10.31219/osf.io/nfv6m>
4. Ronquist F, Teslenko M, Mark P van der, Ayres DL, Darling A, Höhna S, et al. MrBayes 3.2: Efficient bayesian phylogenetic inference and model choice across a large model space. *Systematic biology*, 61(3), 539–542 [Internet]. 2012; Available from: <https://doi.org/10.1093/sysbio/sys029>

5. Nascimento FF, Reis M dos, Yang Z. A biologist's guide to bayesian phylogenetic analysis. *Nat Ecol Evol* 1, 1446–1454 [Internet]. 2017; Available from: <https://doi.org/10.1038/s41559-017-0280-x>
6. Hoang DT, Vinh LS, Flouri T, Stamatakis A, Haeseler A von, Minh BQ. MPBoot: Fast phylogenetic maximum parsimony tree inference and bootstrap approximation. *BMC evolutionary biology*, 18(1), 11 [Internet]. 2018; Available from: <https://doi.org/10.1186/s12862-018-1131-3>
7. Nixon KC. The parsimony ratchet, a new method for rapid parsimony analysis. *Cladistics : the international journal of the Willi Hennig Society*, 15(4), 407–414 [Internet]. 1999; Available from: <https://doi.org/10.1111/j.1096-0031.1999.tb00277.x>
8. Nguyen LT, Schmidt HA, Haeseler A von, Minh BQ. IQ-TREE: A fast and effective stochastic algorithm for estimating maximum-likelihood phylogenies. *Molecular biology and evolution*, 32(1), 268–274 [Internet]. 2015; Available from: <https://doi.org/10.1093/molbev/msu300>
9. Hoang DT, Schmidt H, Trifinopoulos J, Bui M. IQ-TREE: Beginner's tutorial. 2023; Available from: <https://iqtree.github.io/doc/Tutorial>
10. Koehl P, Ripp R, Thompson JD, Poch O. BALiBASE 3.0: Latest developments of the multiple sequence alignment benchmark. *Proteins* 2005 Oct 1;61(1):127-36 [Internet]. 2005; Available from: <https://doi.org/10.1002/prot.20527>
11. Cock PJA, Fields CJ, Goto N, Heuer ML, Rice PM. The sanger FASTQ file format for sequences with quality scores, and the solexa/illumina FASTQ variants. *Nucleic Acids Research* 38 (6): 1767–1771 [Internet]. 2010; Available from: <https://doi.org/10.1093/nar/gkp1137>
12. Sievers F, Wilm A, Dineen D, Gibson TJ, Karplus K, Li W, et al. Fast, scalable generation of high-quality protein multiple sequence alignments using clustal omega. *Molecular systems biology*, 7, 539 [Internet]. 2011; Available from: <https://doi.org/10.1038/msb.2011.75>
13. Gascuel O. BIONJ: An improved version of the NJ algorithm based on a simple model of sequence data. *Molecular biology and evolution*, 14(7), 685–695 [Internet]. 1997; Available from: <https://doi.org/10.1093/oxfordjournals.molbev.a025808>