

Rapport du projet de session

PhyloDendron - Création d'un site web d'inférence d'arbres phylogénétiques

Session Hiver 2026

Date de remise : 06 mai 2026 à 23h59

Enseignant : Dylan Lebatteux

Chelsea Baek et Mariyana Slavova

Table des matières

1	Résumé	2
2	Introduction et problématique	2
2.1	Les objectifs	2
3	Méthodes et matériel	2
3.1	Les algorithmes, outils et logiciels	2
3.2	Le protocole	6
4	Résultats et discussion	8
4.1	ClustalO	8
4.2	MPBoot	8
4.3	IQTREE	9
4.4	MrBayes	9
5	Conclusion	9
6	Références	11
A	Annexe	12
A.1	Tables: ClustalO vs ClustalW	12
A.2	Tables et figures: MPBoot vs PROTPARS	14
A.3	Tables et figures: IQTREE vs RAxML	16
A.4	Figures: MrBayes	18

1 Résumé

Cet article porte sur la création d'un site web d'inférence d'arbres phylogénétiques, nommé **Phylogen-dron.rocks**. Il couvre les divers outils implémentés pour l'alignement, l'inférence phylogénétique et plus encore (conversion de fichiers, visualisation d'arbres). Les raisons pour lesquelles les outils spécifiques ont été sélectionnés ainsi que des tests pour confirmer ces choix sont présentés. Le but ultime de ce projet est de faciliter l'analyse phylogénétique pour les utilisateurs, leur offrant un grand éventail de possibilités pour répondre à leurs besoins spécifiques. Sur le plan personnel, ce projet nous a permis de nous familiariser avec plusieurs langages de programmation, et d'appliquer les connaissances acquises durant le cours BIF7101.

2 Introduction et problématique

L'inférence phylogénétique permet d'étudier les relations évolutives entre les organismes vivants en construisant des arbres à partir de données observées, telles que des séquences d'ADN ou de protéines. Il existe diverses méthodes pour l'inférence, telles que des méthodes de distance, de parcimonie et probabilistes (1). Un obstacle à ce domaine d'étude est le fait de devoir télécharger de nombreux algorithmes avant l'étape de l'analyse. Cela peut grandement ralentir une étude lorsque nous ne sommes pas familier avec l'informatique. C'est pourquoi il existe des sites webs d'inférence d'arbres phylogénétiques. Cependant, nous avons constaté que la plateforme T-REX, créé par Alix Boc, Alpha Boubacar Diallo et Vladimir Makarenkov, qui détermine l'inférence, la validation et la visualisation d'arbres et de réseaux phylogénétiques (2), n'est plus maintenue. En effet, plusieurs méthodes utilisées ont connu des mises à jour qui n'ont pas été reflétées sur le serveur web.

2.1 Les objectifs

L'objectif principal de ce projet est d'offrir aux utilisateurs des outils qui sont à jour et qui ne sont pas disponibles sur T-REX afin qu'ils puissent recevoir de meilleurs résultats, et ce, souvent plus rapidement. Certes, les anciennes versions peuvent encore fonctionner, mais n'offrent pas le meilleur potentiel aux données.

Un second objectif est de créer un site web intuitif et facile d'utilisation. Nous voulons que les utilisateurs puissent télécharger les fichiers produits par les outils d'inférence au besoin et de pouvoir visualiser leurs arbres de diverses manières en leur permettant de changer les paramètres désirés.

3 Méthodes et matériel

3.1 Les algorithmes, outils et logiciels

3.1.1 Informatique

Nous avons utilisé **Git** pour le contrôle de version et le développement collaboratif. Notre *repository* est hébergé sur GitHub.

Développement backend :

- **Langage** : Nous avons choisi de développer le site Web en Python parce que nous voulions utiliser la bibliothèque BioPython (3). BioPython est un ensemble d'outils de biologie computationnelle et de bioinformatique.
- **Framework** : Pour le *framework*, nous avons utilisé **Flask** pour implémenter la gestion des requêtes et des réponses HTTP.

Développement frontend :

Pour développer l'interface utilisateur, nous avons utilisé les trois langages de base:

- **HTML** : Fournit la base structurelle de l'interface web.
- **CSS** : Définit le style visuel et la présentation de l'application.
- **JavaScript** : Permet de rendre le site dynamique et interactif.

De plus, nous avons essayé de respecter les normes d'accessibilité web afin de garantir que la plateforme soit accessible au plus grand nombre. Nous avons utilisé le WebAIM Contrast Checker pour vérifier que les rapports de contraste *text-to-background* et la taille de la police respectent ou dépassent les normes de WebAIM.

Déploiement :

- **Configuration de l'environnement** :
 - **Docker** : Un Dockerfile garantit que toutes les dépendances requises sont installées et configurées de la même manière à chaque exécution, ce qui facilite le déploiement du projet et assure que l'application fonctionne de manière fiable dans n'importe quel environnement, que ce soit en local ou sur un serveur. Notre Dockerfile construit un *container* basé sur Python 3.13, installe et configure les dépendances (MAFFT, Clustal Omega, MrBayes, MUSCLE, IQ-TREE et MPBoot, ainsi que le fichier requirements.txt), puis lance l'application à l'aide de Gunicorn sur le port 8080.
 - **requirements.txt** : contient tous les packages Python nécessaires au projet (flask, gunicorn, biopython, matplotlib).
- **Hosting** : Nous hébergeons notre site pour le rendre accessible aux utilisateurs d'Internet. Notre site Web est hébergé sur DigitalOcean. Nous avons enregistré notre nom de domaine via Name.com et choisi DigitalOcean pour l'hébergement, en profitant du GitHub Student Developer Pack, qui nous offrait un nom de domaine gratuit pendant un an et 200 \$ de crédits DigitalOcean.

3.1.2 Phylogénétique

Nous nous sommes concentrés sur la mise à jour des outils actuellement proposés par T-REX en intégrant des alternatives plus récentes et en ajoutant une méthode bayésienne pour l'inférence d'arbres.

Inférence d'arbre :

Après chaque méthode d'inférence d'arbre, une visualisation de l'arbre est automatiquement générée pour l'utilisateur. Afin d'offrir une expérience plus interactive, nous avons exploré des outils autres que `Phylo.draw()` et `Phylo.draw_ascii()` de BioPython. Pour ce faire, nous avons implémenté Phylocanvas.gl (4), car il propose des fonctionnalités interactives permettant aux utilisateurs d'explorer et de manipuler les arbres phylogénétiques. En plus d'offrir des options similaires à T-REX, notre implémentation permet également d'ajouter des légendes de figures, de appliquer une représentation circulaire de l'arbre et de télécharger celui-ci (Figure 1).




Figure 1: Options PhyloDendron.rocks (gauche) ; Options T-REX (droite)

- **Inférence bayésienne** : Pour l'inférence bayésienne, plutôt que de rechercher un seul arbre optimal, on explore la distribution postérieure des arbres, longueurs de branches et paramètres du modèle. Nous avons utilisé le logiciel MrBayes (5) pour implémenter l'inférence bayésienne en phylogénétique. MrBayes utilise des méthodes de MCMC (Markov Chain Monte Carlo) pour approximer cette distribution a posteriori et estimer les phylogénies et les temps de divergence des espèces (6). Pour construire un arbre de consensus par inférence bayésienne sur notre site Web, l'utilisateur saisit un fichier de séquences alignées (au format FASTA ou NEXUS) ainsi que les paramètres (number of generations, sample frequency, print frequency et number of burn-ins). Si l'utilisateur entre un fichier FASTA, il est automatiquement converti au format NEXUS. Les paramètres par défaut sont également disponibles (Figure 2). Une fois l'analyse terminée, les arbres de consensus obtenus et les résultats sont compilés dans un fichier ZIP téléchargeable.

The image shows a web form for uploading aligned sequences and setting parameters for Bayesian inference. At the top, there's a section 'Upload aligned sequences (FASTA or NEXUS)' with a 'Choose File' button and a note 'no file selected'. Below this is a dropdown menu for 'Intensive (1 000 000 gen)', 'Fast (100 000 gen)' (which is selected), and 'Custom (Manual Entry)'. Under 'Custom Parameters', there are four input fields: 'Number of Generations' (100000), 'Sample Frequency' (100), 'Print Frequency' (10000), and 'Number of Burn-ins' (250). A 'Run MrBayes' button is at the bottom.

Figure 2: Paramètres d'inférence bayésienne

- **Parcimonie** : Pour l'inférence par méthode de parcimonie, nous avons décidé d'implémenter l'outil MPBoot (7) qui n'est pas disponible sur la plateforme T-rex. Ce programme permet également de faire une approximation rapide des bootstraps de parcimonie maximale (UFBoot, inspiré des méthodes similaires employées pour celles de maximum de vraisemblance). Il n'est donc pas nécessaire d'utiliser un outil supplémentaire (ex: SeqBoot) si le calcul des bootstraps est désiré. Pour l'algorithme de recherche, il utilise le réarrangement SPR et implémente le Parsimony ratchet. Cet algorithme permet de trouver les arbres phylogénétiques les plus parcimonieux en effectuant plusieurs cycles échantillonnage et de pondération des sites pour ensuite réaliser des réarrangement des branches en utilisant la méthode SPR. (8). Sur notre plateforme, l'utilisateur télécharge ses séquences alignées en format FASTA et choisit les valeurs des paramètres suivant:

- Ultrafast Bootstraps: Nombre de réplifications pour évaluer la robustesse des branches. Contrairement au bootstrap standard, l'UFBoot est très rapide et réduit le risque de surestimer le support des branches.
- SPR Radius: Indique le rayon de SPR. Un rayon plus grand permet à l'algorithme de déplacer des branches plus loin dans l'arbre, ce qui augmente la possibilité de trouver un optimum global (mais augmente le temps de computation).
- Ratchet Iterations: Nombre de cycles de *ratchet* à effectuer. Plus il y a d'itérations, plus l'algorithme a de chances de s'échapper d'un optimum local pour trouver l'arbre le plus court.
- Ratchet %: Pourcentage de sites dont le poids est modifié à chaque itération. Cela permet de perturber les données pour explorer de nouvelles topologies d'arbres
- Use NNI instead of SPR: Utile lorsqu'une analyse plus rapide est désirée, mais produit un résultat moins strict et minutueux que le réarrangement SPR.

Les paramètres par défaut sont aussi disponibles afin de faciliter la tâche aux utilisateurs (Figure 3). À la fin de l'analyse, plusieurs fichiers informatifs sont disponibles pour le téléchargement (Figure 4).

Maximum Parsimony (MPBoot)
Construct phylogenetic trees using fast maximum parsimony with bootstrap replicates.

Upload aligned sequences (FASTA)
Choose File | No file chosen

Suggested Presets:
Standard (Default Balance)

Parameters

Ultrafast Bootstraps 1000	SPR Radius 6
Ratchet Iterations 1	Ratchet % 50
☐ Use NNI instead of SPR	☐ Store Multiple Hits (-multis)

[Generate Parsimony Tree](#)

Figure 3: Paramètres d'inférence par MPBoot



Figure 4: Fichiers téléchargeables disponibles

- **Maximum de vraisemblance :** Quant à l'inférence par maximum de vraisemblance, l'outil IQTREE (v3.1.1) (9) à été utilisé (non disponible sur T-REX). Ce programme est particulièrement efficace grâce à son algorithme de recherche stochastique. Sur **PhyloDendron.rocks**, l'utilisateur peut ajuster les paramètres suivants : -Substitution Model : Permet de choisir le modèle d'évolution (ex: LG, JTT, WAG). Si l'utilisateur n'est pas certain, l'option MFP active ModelFinder, qui sélectionne automatiquement le meilleur modèle selon le critère BIC. -Ultrafast Bootstraps : Comme pour MPBoot, IQTREE permet d'obtenir rapidement le support des branches avec l'algorithme UFBoot (généralement 1000 réplifications suffisent). -SH-aLRT Replicates : Nombre de répétitions pour le test de rapport de vraisemblance approximatif. Ce test évalue si une branche est nécessaire pour expliquer les données. Un minimum de 1000 répliquas est recommandé.
- **Méthodes de distance :** Pour la construction d'arbres par méthodes de distances, l'utilisateur saisit deux entrées : un fichier FASTA aligné et la méthode de distance, NJ ou UPGMA. Contrairement au plateforme T-REX, où le modèle de substitution est sélectionné manuellement par l'utilisateur, nous avons utilisé IQ-TREE (9) afin de sélectionner le modèle de substitution le plus approprié en

nous basant sur le critère BIC (Bayesian Information Criterion). Le mot-clé MFP (ModelFinder Plus) indique à IQ-TREE d'effectuer l'analyse en utilisant le modèle qui minimise le score BIC [(10).

```
cmd = ["iqtree3", "-s", filepath, "-m", "MFP", "-nt", "AUTO",  
      "-pre", output_prefix, "-redo"]
```

La matrice de distances est générée par IQ-TREE lors de cette sélection de modèle, puis nous la convertissons au format compatible avec Biopython. Enfin, la méthode de distance choisie par l'utilisateur est appliquée à cette matrice pour construire l'arbre phylogénétique, toutes deux implémentées via Biopython (3).

Alignement :

- **MUSCLE** : Nous avons implémenté la version 5 de MUSCLE. Contrairement à la version 3 utilisée sur T-REX, MUSCLE v5 intègre l'algorithme Super5, qui permet d'aligner des ensembles de données beaucoup plus vastes (jusqu'à des dizaines de milliers de séquences) avec une précision élevée et un temps de calcul réduit grâce au *multithreading* (11).
- **MAFFT** : Nous avons intégré MAFFT (version 7), qui est reconnu pour sa rapidité d'exécution sur de larges jeux de données. MAFFT propose plusieurs stratégies d'alignement itératives (comme L-INS-i ou G-INS-i) qui offrent à la fois un alignement précis et rapides, surpassant souvent les performances des versions antérieures (12).
- **Clustal Omega** : ClustalO utilise des HMM pour l'alignement profil-profil ce qui lui permet d'obtenir une meilleure précision, notamment pour les relations phylogénétiques éloignées. Contrairement à son prédécesseur ClustalW qui repose sur une stratégie d'alignement progressif avec pondération des séquences, ClustalO performe mieux sur de grands jeux de données. En effet, sa complexité algorithmique est de $O(n \log n)$ contre $O(n^2)$ pour ClustalW. De plus, ClustalO supporte le *multithreading*, ce qui accélère considérablement les calculs (13). ClustalW est obsolète (plus de support ni de mises à jour), donc l'implémentation de ClustalO sur notre plateforme garantit l'accès à des outils actuels, précis et qui bénéficient d'un soutien technique actif.

Autre Outils :

- **Viewer d'arbre Newick** : Notre plateforme permet aux utilisateurs de téléverser directement un fichier au format Newick (sans avoir à refaire l'inférence) pour visualiser leur arbre. Grâce à Phylo-canvas.gl, les utilisateurs peuvent modifier interactivement la mise en page (circulaire, rectangulaire, radiale) et exporter l'image en haute résolution.
- **Conversion** : Puisque différents outils phylogénétiques exigent différents formats d'entrée (par exemple, MrBayes utilise le format NEXUS, tandis que MPBoot ou d'autres outils requièrent FASTA ou PHYLIP), nous avons développé un outil de conversion de séquences en utilisant le module SeqIO de Biopython. Cela élimine le besoin pour l'utilisateur d'utiliser des scripts externes avant de lancer ses analyses.

3.2 Le protocole

Cette section porte sur des tests effectués afin de valider l'implémentation des nouveaux outils (ClustalO, MPBoot, IQTREE et MrBayes) en les comparant avec un outil semblable disponible sur T-REX. Les tableaux et les visualisations d'arbres sont disponibles dans l'annexe.

3.2.1 Jeux de données

Afin de tester les outils, plusieurs groupes de séquences d'acides aminés de référence ont été téléchargées de la base de données BaliBASE (Benchmark Alignment dataBASE). Cette base de données est un répertoire utilisé fréquemment pour tester des outils d'alignement de séquence multiples (14). Nous allons donc l'employer d'abord pour évaluer la performance de ClustalO, et ensuite utiliser ces mêmes résultats d'alignement pour l'évaluation des autres outils phylogénétiques. Ce qui distingue principalement ce jeu de données est le fait que les séquences comportent une identité de séquence très basse (moins de 25%), offrant alors un vrai test de stress à nos outils.

3.2.2 Tester ClustalO

Pour tester la performance de ClustalO contre son prédécesseur ClustalW, nous avons voulu calculer le temps d'exécution et la qualité de l'alignement. Pour le test de vitesse, ClustalO et ClustalW ont été exécutés à 5 reprises sur 3 groupes de séquences de taille différente (261, 1044, 2088) prises de BaliBASE, et la moyenne du temps a été retenue pour chaque groupe.

Pour le test de qualité de l'alignement, les alignements produits par ClustalO et ClustalW ont été appliqués sur IQTREE3 et les résultats du score de maximum de vraisemblance de l'arbre optimal généré de chacun a été comparé. Le meilleur alignement sera donc celui avec le score de maximum de vraisemblance le plus bas.

3.2.3 Tester MPBoot

Afin de tester la performance de MPBoot, nous avons décidé de le comparer à un des algorithmes de maximum de parcimonie disponible sur T-REX. PROTPARS de la suite Phylips a été choisi. Il est spécifiquement programmé pour l'analyse de séquence d'acides aminés. Les alignements de séquences générés par ClustalO à l'étape précédente sont repris, puis sont téléchargés dans MPBoot et PROTPARS. Notez que PROTPARS n'acceptent que les fichiers Phylips, donc nous les avons convertis à l'aide de l'outil de conversion disponible sur **Phylodendron.rocks**. Puisque ces deux algorithmes performant très rapidement (moins de 1 seconde par groupe de séquence dans notre jeu de données), seulement le score de parcimonie de chacun a été comparé.

3.2.4 Tester IQTREE

Afin d'évaluer l'efficacité de notre implémentation de maximum de vraisemblance, nous avons comparé IQTREE (v3.1.1) à RAxML. Ces deux algorithmes sont reconnus pour leur puissance, mais IQ-TREE utilise une approche de recherche stochastique souvent plus efficace et plus rapide. Les alignements générés par ClustalO ont été analysés par les deux outils. Nous avons comparé le temps d'exécution ainsi que le score final de log-vraisemblance pour déterminer quel outil trouvait l'arbre optimal le plus rapidement. Afin de ne pas biaiser les résultats, les modèles LG+G ont été assignés aux deux algorithmes puisque nous avons déjà testé la puissance du paramètre ModelFinder en classe.

3.2.5 Tester MrBayes

Afin de valider l'outil MrBayes, nous avons uniquement utilisé le jeu de données BB11018. Contrairement aux méthodes de maximum de vraisemblance, MrBayes utilise l'inférence bayésienne pour explorer l'espace des arbres via des chaînes de Markov (MCMC). Pour ce test, nous avons configuré l'analyse avec les paramètres *Fast presets* présents dans **Phylodendron.rocks**, donc un total de 100 000 générations avec une fréquence d'échantillonnage de 100. Nous avons aussi appliqué un burn-in de 250 pour éliminer les premiers arbres de la chaîne qui ne sont pas encore à l'équilibre. L'objectif était de voir si en utilisant ces réglages, MrBayes arrivait à une topologie stable et cohérente avec nos autres outils. Pour ce faire, nous avons entrepris une visualisation des arbres phylogénétiques calculés par MPBoot, IQ-TREE et MrBayes.

4 Résultats et discussion

4.1 ClustalO

Test de vitesse :

La figure 5 ci dessous démontre que, en augmentant le nombre de séquences, ClustalO performe mieux que ClustalW. En effet, sur de courtes séquences, ClustalW est plus rapide, mais il augmente de manière exponentielle en augmentant la taille du jeu de données.




Figure 5: Moyenne du temps d'exécution de ClustalO et ClustalW sur 3 groupes de séquences de taille différente

Test de la qualité de l'alignement :

Le tableau 3 dans l'annexe démontre que ClustalO effectue un meilleur alignement que ClustalW selon le score de maximum de vraisemblance produit par IQTREE, échouant seulement 5 fois sur 38. D'ailleurs, le tableau 2 en annexe affiche les statistiques des séquences alignées. Nous pouvons apercevoir que ce sont les groupes de séquences moins nombreuses et courtes qui produisent un meilleur résultat. Cela correspond à la littérature (13). Néanmoins, ClustalO s'avère plus performant pour le traitement de jeux de données larges. Contrairement à ClustalW, qui utilise un alignement progressif classique, ClustalO repose sur des modèles de Markov cachés pour l'alignement profil-profil. Cette approche permet de garder une meilleure précision sur des séquences très divergentes, comme celles de BaliBASE où l'identité est souvent moins de 25 %. L'intégration de cet outil sur PhyloDendron.rocks assure donc une précision accrue tout en supportant le *multithreading* pour réduire les temps de calcul.

4.2 MPBoot

Le tableau 4 dans l'annexe illustre les scores de parcimonies calculés par MPBoot et PROTPARS. Nous avons pu démontrer que MPBoot trouvait pour chaque groupe un meilleur arbre consensus. Cette différence de performance est expliquée par le fait que PROTPARS est un outil plus ancien qui utilise une méthode de parcimonie d'Eck et Dayoff (parcimonie des protéines) dont les algorithmes de recherche sont moins exhaustifs. De plus, PROTPARS ne possède pas de fonction de bootstrapping intégrée, ce qui oblige l'utilisateur à passer par des étapes supplémentaires et souvent plus lentes (comme l'utilisation de SeqBoot) pour évaluer la robustesse de l'arbre. En revanche, MPBoot permet de réaliser des analyses de parcimonie beaucoup plus poussées en intégrant directement le bootstrapping ultra-rapide (UFBoot). L'adoption de cet outil sur PhyloDendron.rocks permet donc de contrer les manques de T-REX en offrant une solution plus précise et plus flexible pour l'inférence par parcimonie.

4.3 IQTREE

Le tableau 5 dans l'annexe démontre les scores de log-vraisemblance et le temps d'exécution des deux algorithmes. Nous pouvons constater que les scores sont très similaires, démontrant que les deux outils arrivent à la même qualité d'arbre pour ces jeux de données. Cependant, la différence se joue au niveau du temps de calcul. Bien que RAxML s'est démontré plus rapide 17 fois sur 38, ce n'est seulement que pour une trentaine de secondes. En effet, le temps le plus long n'était que de 66 secondes pour le jeu BB11018, alors que cela a pris 1122 secondes à RAxML. Cette rapidité s'explique par son algorithme de recherche stochastique qui explore l'espace des arbres de manière plus optimale en évitant les calculs redondants sans sacrifier la précision du score de log-vraisemblance. En intégrant IQ-TREE dans **PhyloDendron.rocks**, nous offrons donc une solution qui maintient la rigueur de la méthode de maximum de vraisemblance tout en minimisant l'attente pour l'utilisateur, ce qui est crucial pour une plateforme web.

4.4 MrBayes

Même avec un nombre de générations relativement court (100 000), la topologie de l'arbre obtenue à l'aide de MrBayes (voir Figure 10) est identique à celle d'IQ-TREE (Figure 8) et de MPBoot (Figure 6). Les probabilités postérieures sont très élevées (Figure 11), montrant que la chaîne a bien convergé vers une solution fiable. Malheureusement, nous n'avons pas encore implémenté la visualisation des probabilités a posteriori sur notre interface. Par contre, notons que MrBayes est beaucoup plus lent. En effet, pour le même dataset, il prend plusieurs minutes là où IQ-TREE finit en quelques secondes. C'est pour cette raison que nous avons intégré des paramètres manuels dans l'interface de **PhyloDendron.rocks**. Cela permet à l'utilisateur de choisir rapidement entre une analyse rapide ou une exploration plus poussée.

5 Conclusion

L'objectif principal de ce projet était de fournir aux utilisateurs une plateforme Web moderne pour l'inférence phylogénétique, intégrant des outils récents non disponibles sur la plateforme T-REX, tout en améliorant la facilité d'utilisation.

L'utilisabilité est améliorée grâce à l'intégration de paramètres prédéfinis suggérés. De plus, les arbres inférés sont automatiquement générés et affichés à la fin de chaque analyse, donc aucun outil supplémentaire n'est nécessaire pour visualiser l'arbre.

PhyloDendron.rocks constitue une extension de T-REX dans plusieurs domaines (résumé dans la table 1). Pour l'inférence d'arbres phylogénétiques, l'intégration d'IQ-TREE, MPBoot et MrBayes permet aux utilisateurs d'accéder à ces méthodes (non disponibles sur T-REX). Pour l'alignement de séquences, des outils tels que MUSCLE, MAFFT et ClustalO offrent des alignements plus rapides et plus précis que les versions précédentes, notamment pour les grands ensembles de données. Enfin, nous permettons aux utilisateurs de télécharger des fichiers Newick pour la visualisation et de convertir des fichiers.

Des améliorations peuvent être apportées pour optimiser la portée et les performances de PhyloDendron.rocks. Il existe de nombreux autres outils phylogénétiques qui vont au-delà de ceux que nous avons implémentés et de ceux disponibles sur T-REX. Par exemple, nous pourrions ajouter un outil d'inférence bayésienne, tel que BEAST, qui estime les dates de divergence entre espèces à partir de séquences et de calibrations fossiles ou biogéographiques.

Une autre amélioration concerne le logiciel. Nous pourrions implémenter une exécution asynchrone pour les analyses nécessitant une puissance de calcul importante, telles que MrBayes, ce qui permettrait aux utilisateurs de continuer à utiliser la plateforme pendant que les calculs sont en cours.

```
##  
## Attaching package: 'dplyr'
```

```
## The following object is masked from 'package:kableExtra':
##
##   group_rows

## The following objects are masked from 'package:stats':
##
##   filter, lag

## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

Table 1: Résumé des outils utilisés

Catégorie	Méthode	PhyloDendron	TREX
Inférence d'arbre	Inférence bayésienne	Utilise MrBayes pour estimer les phylogénies des espèces et les temps de divergence	Pas disponible
	Parcimonie	MPBoot ; Inclut l'algorithme UFBoot et accepte les séquences d'ADN et de protéines.	PROTPARS ; Prend uniquement des séquences d'acides aminés et n'a pas d'option de bootstrap intégré.
	Maximum de vraisemblance	IQTREE ;	RAxML ; Méthode classique performante, mais souvent plus lente sur les gros jeux de données
	Méthodes de distance	Choisit automatiquement le meilleur modèle de substitution selon le BIC	Les utilisateurs saisissent leur choix de modèle de substitution
Alignement	MUSCLE	MUSCLE v5 ; plus précis et plus rapide (utilise multithreading) que v3	MUSCLE v3
	MAFFT	MAFFT v7	MAFFT v6
	Clustal	ClustalO ; plus rapide pour les séquences plus longues	ClustalW ; plus rapide pour les séquences plus courtes
Autres outils	Viewer d'arbre Newick	Plus d'options pour manipuler l'arbre que T-REX	Options pour manipuler l'arbre
	Conversion	Conversion entre différents types de fichiers	Pas disponible

6 Références

1. Haber M, Velasco J. Phylogenetic inference. In: The Stanford Encyclopedia of Philosophy (Summer 2024 Edition), Edward N Zalta & Uri Nodelman (eds) [Internet]. 2024; Available from: <https://plato.stanford.edu/archives/sum2024/entries/phylogenetic-inference/>
2. Boc A, Diallo AB, Makarenkov V. T-REX: A web server for inferring, validating and visualizing phylogenetic trees and networks. *Nucleic Acids Research*, Volume 40, Issue W1 [Internet]. 2012; Available from: <https://doi.org/10.1093/nar/gks485>
3. Cock PJA, Antao T, Chang JT, Chapman BA, Cox CJ, Dalke A, et al. Biopython: Freely available python tools for computational molecular biology and bioinformatics. *Bioinformatics* 25 (11), 1422–1423 () [Internet]. 2009; Available from: <https://doi.org/10.1093/bioinformatics/btp163>
4. Abudahab K, Underwood A, Taylor B, Yeats C, Aanensen DM. PhyloCanvas.gl: A WebGL-powered JavaScript library for large tree visualisation. 2021; Available from: <https://doi.org/10.31219/osf.io/nfv6m>
5. Ronquist F, Teslenko M, Mark P van der, Ayres DL, Darling A, Höhna S, et al. MrBayes 3.2: Efficient bayesian phylogenetic inference and model choice across a large model space. *Systematic biology*, 61(3), 539–542 [Internet]. 2012; Available from: <https://doi.org/10.1093/sysbio/sys029>
6. Nascimento FF, Reis M dos, Yang Z. A biologist’s guide to bayesian phylogenetic analysis. *Nat Ecol Evol* 1, 1446–1454 [Internet]. 2017; Available from: <https://doi.org/10.1038/s41559-017-0280-x>
7. Hoang DT, Vinh LS, Flouri T, Stamatakis A, Haeseler A von, Minh BQ. MPBoot: Fast phylogenetic maximum parsimony tree inference and bootstrap approximation. *BMC evolutionary biology*, 18(1), 11 [Internet]. 2018; Available from: <https://doi.org/10.1186/s12862-018-1131-3>
8. Nixon KC. The parsimony ratchet, a new method for rapid parsimony analysis. *Cladistics : the international journal of the Willi Hennig Society*, 15(4), 407–414 [Internet]. 1999; Available from: <https://doi.org/10.1111/j.1096-0031.1999.tb00277.x>
9. Nguyen LT, Schmidt HA, Haeseler A von, Minh BQ. IQ-TREE: A fast and effective stochastic algorithm for estimating maximum-likelihood phylogenies. *Molecular biology and evolution*, 32(1), 268–274 [Internet]. 2015; Available from: <https://doi.org/10.1093/molbev/msu300>
10. Hoang DT, Schmidt H, Trifinopoulos J, Bui M. IQ-TREE: Beginner’s tutorial. 2023; Available from: <https://iqtree.github.io/doc/Tutorial>
11. Edgar RC. Muscle5: High-accuracy alignment ensembles enable unbiased assessments of sequence homology and phylogeny. *Nat Commun* 13, 6968 [Internet]. 2022; Available from: <https://doi.org/10.1038/s41467-022-34630-w>
12. Katoh K, Standley DM. MAFFT multiple sequence alignment software version 7: Improvements in performance and usability. *Molecular Biology and Evolution*, Volume 30, Issue 4 [Internet]. 2013; Available from: <https://doi.org/10.1093/molbev/mst010>
13. Sievers F, Higgins DG. Clustal omega for making accurate alignments of many protein sequences. *Protein science : a publication of the Protein Society*, 27(1), 135–145 [Internet]. 2018; Available from: <https://doi.org/10.1002/pro.3290>
14. Koehl P, Ripp R, Thompson JD, Poch O. BALiBASE 3.0: Latest developments of the multiple sequence alignment benchmark. *Proteins* 2005 Oct 1;61(1):127–36 [Internet]. 2005; Available from: <https://doi.org/10.1002/prot.20527>
15. Cock PJA, Fields CJ, Goto N, Heuer ML, Rice PM. The sanger FASTQ file format for sequences with quality scores, and the solexa/illumina FASTQ variants. *Nucleic Acids Research* 38 (6): 1767–1771 [Internet]. 2010; Available from: <https://doi.org/10.1093/nar/gkp1137>
16. Sievers F, Wilm A, Dineen D, Gibson TJ, Karplus K, Li W, et al. Fast, scalable generation of high-quality protein multiple sequence alignments using clustal omega. *Molecular systems biology*, 7, 539 [Internet]. 2011; Available from: <https://doi.org/10.1038/msb.2011.75>

A Annexe

A.1 Tables: ClustalO vs ClustalW

Table 2: Statistiques des alignements de séquences produits par ClustalO et ClustalW

DataSet ClustalO	Nbr de seq	Longueur	% Identité	DataSet ClustalW	Nbr de seq	Longueur	% Identité
BB11001_o	4	96	16.83	BB11001_w	4	96	17.37
BB11002_o	8	287	8.78	BB11002_w	8	202	9.84
BB11003_o	4	589	15.16	BB11003_w	4	569	14.24
BB11004_o	4	634	11.80	BB11004_w	4	466	10.33
BB11005_o	14	616	10.70	BB11005_w	14	542	10.22
BB11006_o	8	453	9.39	BB11006_w	8	330	9.03
BB11007_o	9	545	14.52	BB11007_w	9	479	14.48
BB11008_o	4	620	6.98	BB11008_w	4	550	8.23
BB11009_o	4	446	8.22	BB11009_w	4	341	7.96
BB11010_o	4	656	15.12	BB11010_w	4	533	13.96
BB11011_o	5	331	8.49	BB11011_w	5	253	8.97
BB11012_o	4	414	19.27	BB11012_w	4	408	20.33
BB11013_o	5	127	7.10	BB11013_w	5	103	8.78
BB11014_o	6	667	18.97	BB11014_w	6	655	18.25
BB11015_o	4	351	18.21	BB11015_w	4	333	16.49
BB11016_o	8	1019	10.82	BB11016_w	8	729	10.56
BB11017_o	4	310	17.64	BB11017_w	4	287	17.53
BB11018_o	14	1195	9.92	BB11018_w	14	915	10.34
BB11019_o	10	481	15.17	BB11019_w	10	430	14.66
BB11020_o	9	296	13.55	BB11020_w	9	274	14.23
BB11021_o	4	183	14.29	BB11021_w	4	143	12.28
BB11022_o	4	227	6.91	BB11022_w	4	205	6.74
BB11023_o	7	452	12.48	BB11023_w	7	412	11.20
BB11024_o	4	709	9.13	BB11024_w	4	482	9.69
BB11025_o	4	121	8.87	BB11025_w	4	116	9.83
BB11026_o	7	929	4.87	BB11026_w	7	910	7.90
BB11027_o	7	452	10.98	BB11027_w	7	432	10.83
BB11028_o	10	258	10.02	BB11028_w	10	233	9.35
BB11029_o	4	148	14.03	BB11029_w	4	143	15.81
BB11030_o	14	528	11.14	BB11030_w	14	402	10.17
BB11031_o	11	938	9.07	BB11031_w	11	620	8.55
BB11032_o	8	550	11.41	BB11032_w	8	505	11.65
BB11033_o	11	380	7.81	BB11033_w	11	267	9.01
BB11034_o	8	1015	11.39	BB11034_w	8	730	10.97
BB11035_o	5	161	12.21	BB11035_w	5	155	15.28
BB11036_o	8	550	13.02	BB11036_w	8	481	12.45
BB11037_o	5	1276	9.12	BB11037_w	5	1199	8.19
BB11038_o	8	735	13.84	BB11038_w	8	656	12.31

Table 3: Log-Likelihood Comparison: ClustalO vs ClustalW

DataSet	LogL ClustalO	LogL ClustalW	Difference $\Delta \ln L$
BB11001	-886.8577	-880.2027	-6.6550
BB11002	-2092.8031	-2138.9514	46.1483
BB11003	-5030.4580	-5098.8827	68.4247
BB11004	-4615.6993	-4774.8269	159.1276
BB11005	-14630.4153	-15165.8266	535.4113
BB11006	-5282.8166	-5417.3120	134.4954
BB11007	-9765.0703	-9922.5041	157.4338
BB11008	-3375.1971	-3430.4828	55.2857
BB11009	-2361.1142	-2434.4417	73.3275
BB11010	-5296.4244	-5418.3610	121.9366
BB11011	-2731.2691	-2820.7413	89.4722
BB11012	-3770.0699	-3763.0219	-7.0480
BB11013	-969.4768	-968.2593	-1.2175
BB11014	-8314.4902	-8452.9537	138.4635
BB11015	-3234.5981	-3292.1999	57.6018
BB11016	-10039.5630	-10247.2661	207.7031
BB11017	-2598.3897	-2626.9057	28.5160
BB11018	-20003.4046	-20760.0193	756.6147
BB11019	-8899.0217	-9146.2204	247.1987
BB11020	-5153.3726	-5210.8447	57.4721
BB11021	-1233.8427	-1282.9823	49.1396
BB11022	-1276.6726	-1300.0592	23.3866
BB11023	-5638.6468	-5831.1325	192.4857
BB11024	-4456.0704	-4588.0246	131.9542
BB11025	-923.0119	-931.2419	8.2300
BB11026	-4657.8646	-4714.7125	56.8479
BB11027	-4284.2234	-4439.6467	155.4233
BB11028	-4216.0853	-4296.8722	80.7869
BB11029	-1086.7838	-1078.2361	-8.5477
BB11030	-10651.6158	-11165.8629	514.2471
BB11031	-11133.2634	-11543.2571	409.9937
BB11032	-6286.5781	-6418.5129	131.9348
BB11033	-4408.0949	-4510.4079	102.3130
BB11034	-10452.9627	-10742.5782	289.6155
BB11035	-1290.1666	-1258.5651	-31.6015
BB11036	-7776.1299	-7950.9448	174.8149
BB11037	-7235.1302	-7380.3570	145.2268
BB11038	-7586.3363	-7857.6230	271.2867

A.2 Tables et figures: MPBoot vs PROTPARS

A.2.1 Table: MPBoot vs PROTPARS

Table 4: Parsimony Score Comparison: MPBoot vs PROTPARS

DataSet	MPBoot score	PROTPARS score	Difference Δ Score
BB11001	173	294	121
BB11002	339	1443	1104
BB11003	909	1989	1080
BB11004	751	2295	1544
BB11005	3239	6799	3560
BB11006	1018	2772	1754
BB11007	2090	3981	1891
BB11008	435	2381	1946
BB11009	295	1768	1473
BB11010	917	2334	1417
BB11011	495	1707	1212
BB11012	702	1365	663
BB11013	172	665	493
BB11014	1636	3090	1454
BB11015	612	1089	477
BB11016	1840	5492	3652
BB11017	470	967	497
BB11018	4184	11724	7540
BB11019	1896	3712	1816
BB11020	1113	2233	1120
BB11021	193	653	460
BB11022	183	897	714
BB11023	1152	2590	1438
BB11024	667	2772	2105
BB11025	159	488	329
BB11026	536	3785	3249
BB11027	780	2288	1508
BB11028	910	2004	1094
BB11029	184	508	324
BB11030	2311	5370	3059
BB11031	2156	6697	4541
BB11032	1221	3009	1788
BB11033	861	2638	1777
BB11034	1956	5607	3651
BB11035	225	651	426
BB11036	1614	3673	2059
BB11037	950	4717	3767
BB11038	1423	3904	2481

A.2.2 Arbres consensus MPBoot vs PROTPARS




Figure 6: Arbre consensus MPBoot du jeu de données BB11018 - Visualisation via Phylodendron.rocks




Figure 7: Arbre consensus PROTPARS du jeu de données BB11018 - Visualisation via T-REX

A.3 Tables et figures: IQTREE vs RAxML

A.3.1 Table: IQTREE vs RAxML

Table 5: LogL Score and Time Comparison: IQTREE vs RAxML

DataSet	IQTREE LogL	RAxML LogL	IQTREE Time	RAxML Time	Difference Δ Time
BB11001	-932.7975	-932.8367	32.62	1.71	-30.91
BB11002	-2093.2598	-2093.2660	40.27	94.62	54.35
BB11003	-5030.4587	-5030.4868	45.63	9.29	-36.34
BB11004	-4615.7059	-4615.7178	43.39	9.99	-33.40
BB11005	-14634.6412	-14634.6442	55.90	643.54	587.64
BB11006	-5298.2923	-5298.3009	38.17	121.07	82.90
BB11007	-9776.0245	-9776.0287	43.96	213.39	169.43
BB11008	-3382.2207	-3382.2530	38.41	9.65	-28.76
BB11009	-2370.9981	-2371.0654	41.16	8.21	-32.95
BB11010	-5304.0617	-5304.1195	38.13	10.39	-27.74
BB11011	-2747.4402	-2747.4484	37.40	30.54	-6.86
BB11012	-3770.8745	-3770.8894	36.34	10.04	-26.30
BB11013	-968.7549	-968.8047	37.97	11.98	-25.99
BB11014	-8314.7669	-8314.7739	37.69	104.08	66.39
BB11015	-3234.1104	-3234.1313	40.26	4.88	-35.38
BB11016	-10053.8613	-10053.8790	47.11	222.40	175.29
BB11017	-2606.1492	-2606.1662	36.28	8.74	-27.54
BB11018	-20238.2488	-20238.2508	66.40	1122.04	1055.64
BB11019	-8933.7061	-8933.7157	40.41	212.77	172.36
BB11020	-5153.3728	-5153.3797	35.89	120.14	84.25
BB11021	-1246.1784	-1246.2185	35.32	4.02	-31.30
BB11022	-1276.5000	-1276.5200	34.37	4.20	-30.17
BB11023	-5733.0518	-5733.0598	38.59	103.81	65.22
BB11024	-4453.3528	-4453.3809	32.82	8.50	-24.32
BB11025	-922.3562	-922.3866	36.09	2.67	-33.42
BB11026	-4677.8854	-4677.9280	35.28	133.31	98.03
BB11027	-4284.2235	-4284.2346	36.98	56.31	19.33
BB11028	-4231.7223	-4231.7431	35.80	174.71	138.91
BB11029	-1096.6443	-1096.6787	34.13	2.11	-32.02
BB11030	-10668.7914	-10668.7979	46.76	609.87	563.11
BB11031	-11255.5932	-11255.5986	41.61	424.34	382.73
BB11032	-6290.1084	-6290.1134	35.54	140.79	105.25
BB11033	-4422.3110	-4422.3248	37.97	207.37	169.40
BB11034	-10471.3425	-10471.3600	41.27	188.15	146.88
BB11035	-1306.1514	-1306.1878	30.88	16.29	-14.59
BB11036	-7791.1178	-7791.1329	35.25	168.84	133.59
BB11037	-7277.8673	-7277.8861	38.81	40.96	2.15
BB11038	-7586.3357	-7586.3420	38.53	173.47	134.94

A.3.2 Arbres consensus IQTREE vs RAxML




Figure 8: Arbre consensus IQTREE du jeu de données BB11018 - Visualisation via Phyloendron.rocks




Figure 9: Arbre consensus RAxML du jeu de données BB11018 - Visualisation via T-REX

A.4 Figures: MrBayes

A.4.1 Arbres consensus MrBayes




Figure 10: Arbre consensus MrBayes du jeu de données BB11018 - Visualisation via Phyloendron.rocks




Figure 11: Arbre consensus MrBayes du jeu de données BB11018 avec les probabilités à posteriori